

# Statystyczna analiza danych SAD-2018

Wykład 2



(MODELE PROBABILISTYCZNE)



## **Definicja 1**

#### Doświadczenie losowe:

- może być powtarzane w tych samych warunkach,
- wynik nie jest znany przed wykonaniem doświadczenia,
- znany jest zbiór wszystkich możliwych wyników
   opisany przed przeprowadzeniem doświadczenia
  - opisany przed przeprowadzeniem doświadczenia.



## **Przykłady:**

Doświadczenie	Wyniki
podanie lekarstwa	{leczy, nie leczy}
czas życia elementu (np. procesora)	$[0,\infty)$
czas naprawy elementu	$[0,\infty)$
liczba błędów w aplikacji	{0,1,2,}
liczba orłów w 100 rzutach monetą	{0,1,2,,100}
liczba samochodów na autostradzie w godzinach szczytu	{0,1,2,}



## **Definicja 2**

- Przestrzenią zdarzeń elementarnych (przestrzenią próbkową) nazywamy zbiór wszystkich możliwych wyników doświadczenia losowego i oznaczamy symbolem S.
- **Zdarzeniem elementarnym** nazywamy każdy element przestrzeni S ( $s \in S$ ); s niepodzielny (pojedynczy) wynik doświadczenia losowego.
- **Zdarzenie to** podzbiór przestrzeni S ( $A \subset S$ ,  $B \subset S$ ).
- **Zdarzenie** A **zaszło**, gdy wynik doświadczenia losowego (zdarzenie elementarne) jest elementem zbioru A.



## Przykłady:

- Rzut monetą:  $S = \{O, R\}$  skończona, Podzbiory S (zdarzenia):  $\emptyset$ ,  $\{O\}$ ,  $\{R\}$ , S.
- Podwójny rzut kostką sześcienną:

$$S = \{(i, j): i, j = 1, 2, ..., 6\}$$
 - skończona.

Np.  $A = \{$ suma oczek nieparzysta mniejszych od  $6 \}$ 

$$= \{ (1,2), (1,4), (3,2), (2,1), (4,1), (2,3) \}.$$



Czas obsługi klienta w systemie masowej obsługi (np. sieć telefoniczna, komputerowa, czas mierzony w min.):  $S = [0, \infty)$  - nieskończona, nieprzeliczalna. Zdarzenia – podprzedziały S, np.: A = [0, 5), B = [0, T),  $C = [0, \infty)$ , ( $A = \{$ obsługa klienta trwa krócej niż 5 min. $\}$ )

Liczba awarii urządzenia w określonym czasie:  $S = \{0,1,2,...\}$  - nieskończona, przeliczalna.



# Zdarzenia utożsamiamy ze zbiorami stąd: rachunek zdarzeń $\Leftrightarrow$ rachunek zbiorów.

#### **Definicja 3**

- **Zdarzenie przeciwne do**  $A \Leftrightarrow dopełnienie zbioru <math>A$ A' = S - A
- Iloczyn zdarzeń A i  $B \Leftrightarrow$  iloczyn zbiorów A i B  $A \cap B$
- Suma zdarzeń A i  $B \Leftrightarrow$  suma zbiorów A i B:  $A \cup B$
- **Różnica zdarzeń** A i  $B \Leftrightarrow$  różnica zbiorów A i B: A B



- Zdarzenia A i B wzajemnie się wykluczają, jeśli  $A \cap B = \emptyset$ , gdzie  $\emptyset$  jest zbiorem pustym.
- **Z**ajście zdarzenia A pociąga za sobą zajście zdarzenia B, jeśli  $A \subset B$
- Diagramy Venna ilustracja działań na zdarzeniach.



## **Definicja 4**

Zdarzenia  $A_1, A_2, A_3,...$  wzajemnie się wykluczają, jeśli dowolne dwa zdarzenia  $A_i$  oraz  $A_j, i \neq j$ , wzajemnie się wykluczają:  $A_i \cap A_j = \emptyset$ , dla dowolnych  $i, j, i \neq j$ .

## <u>Uwaga</u>

$$A \cup B = (A \cap B) \cup (A - B) \cup (B - A)$$

$$A - B = A \cap B'$$
  $B - A = B \cap A'$ .

,

10



## **PRAWDOPODOBIEŃSTWO**

**Eksperyment Karla Pearsona** (1857-1936):

Wykonał 24 000 rzutów monetą. Częstość wyrzucenia orła wyniosła

n/N = 0.5005

Szansa (prawdopodobieństwo) zajścia zdarzenia A = graniczna częstość wystąpienia, A przy nieograniczenie rosnącej liczbie powtórzeń doświadczenia losowego.



## **Definicja 5** (aksjomatyczna prawdopodobieństwa, A. Kołmogorow, 1933)

(A1) Dla każdego 
$$A, A \subset S$$
,  $0 \le P(A) \le 1$ 

**(A2)** 
$$P(S) = 1, P(\emptyset) = 0$$

(A3) Jeśli zdarzenia  $A_1, A_2, A_3,...$  wzajemnie się wykluczają, to  $P(A_1 \cup A_2 \cup A_3...) = P(A_1) + P(A_2) + P(A_3) + ...$ 



## Uwaga Z (A3) wynika

$$P(A_1 \cup A_2 \cup ... \cup A_n) = P(A_1) + P(A_2) + ... + P(A_n)$$

**Stwierdzenie 1** Niech  $S = \{s_1, s_2, ..., s_M\}$ .

Jeśli 
$$P({s_1}) = P({s_2}) = ... = P({s_M}),$$

to dla dowolnego  $\,m$  - elementowego podzbioru A zbioru S zachodzi

$$P(A) = \frac{m}{M}$$

$$P(A) = \sum_{s_i \in A} P(\{s_i\})$$



Z aksjomatów (A2), (A3) i założenia o jednakowym prawdopodobieństwie jednoelementowych zdarzeń:

$$1 = P(S) = P(\{s_1\}) + P(\{s_2\}) + ...P(\{s_M\}) = M \times P(\{s_i\})$$

gdzie i = 1,2,..., M. Stąd  $P(\{s_i\}) = 1/M$ .

$$A = \{s_{i_1}, s_{i_2}, ..., s_{i_m}\}, 1 \le i_1 < i_2 < ... < i_m \le M,$$

$$P(A) = P(\{s_{i_1}\}) + P(\{s_{i_2}\}) + ... + P(\{s_{i_m}\}) = m \times \frac{1}{M} = \frac{m}{M}.$$



## Przykład:

Oblicz P(A), gdzie  $A = \{$ wypadnięcie orła po raz pierwszy za trzecim razem, w trzech rzutach monetą symetryczną $\}$ .

 $S = \{OOO, OOR, ORO, ROO, ORR, ROR, RRO, RRR\}.$ 

Liczebność  $S = 2^3 = 8$ , liczebność A = 1.

Zatem 
$$P(A) = \frac{1}{8}$$
.



#### Wzory obliczeniowe kombinatoryki

**Kombinacja** (k – elementowa) to k - elementowy podzbiór zbioru n – elementowego.

Liczba k - elementowych kombinacji zbioru n - elementowego,

$$C(n,k) = \binom{n}{k} = \frac{n!}{k!(n-k)!}$$
$$0! = 1.$$

Przykład: Ile jest możliwych wyborów 2 asów z talii 52 kart?

$$C(4,2) = {4 \choose 2} = \frac{4!}{2! \times 2!} = 6.$$

$$V(n,k) = n(n-1)(n-2) \times ... \times (n-k+1) =$$

 $C(n,k) \times k! = \text{liczba } k - \text{elementowych wariacji bez}$ powtórzeń n - elementowego zbioru,  $k \le n$ 

**Przykład**. Ile jest możliwych sposobów opuszczenia windy przez 5 osób w bloku 10 –cio piętrowym w taki sposób, że nie ma osób wysiadających na tych samych piętrach?

$$V(10,5) = 10 \times 9 \times 8 \times 7 \times 6 = 30240.$$



Zadanie. Losujemy 13 kart z talii 52 kart ( np. w brydżu ).

$$P(\text{zestaw 6 pik\'ow}) = \frac{\binom{13}{6}\binom{39}{7}}{\binom{52}{13}} = ?$$

P(4 karty tej samej wysokości) =

$$\frac{\binom{13}{1}\binom{4}{4}\binom{48}{9}}{\binom{52}{13}} = ?$$



#### Twierdzenie 1

Niech  $A \subset S$ . Wówczas

$$P(A') = 1 - P(A)$$

#### Dowód.

$$A \bigcup A' = S$$
,  $A \cap A' = \emptyset$ .

Z definicji 5: 
$$P(A \cup A') = P(A) + P(A') = P(S) = 1$$
,  $\Box$ 

#### Przykład.

Prawdopodobieństwo wyrzucenia co najmniej jednego orła w trzech rzutach monetą symetryczną:

$$1 - \frac{1}{8} = \frac{7}{8}$$
.



#### **Twierdzenie 2**

Niech  $A \subset S$  i  $B \subset S$  oraz  $A \subset B$ . Wówczas

$$P(A) \le P(B)$$
.

#### Dowód

$$B = A \bigcup (B - A)$$
 oraz  $A \bigcap (B - A) = \emptyset$ .

Zatem z definicji 5:

$$P(B) = P(A) + P(B-A) \ge P(A)$$
, gdyż  $P(B-A) \ge 0$ .  $\square$ 



#### **Twierdzenie 3.** Niech $A \subset S$ i $B \subset S$ . Wówczas

$$P(A \bigcup B) = P(A) + P(B) - P(A \cap B),$$

$$P(A \cup B) = P(A) + P(B)$$
, jeśli  $A \cap B = \emptyset$ .

#### **Dowód**

$$A \bigcup B = (A \cap B) \bigcup (A - B) \bigcup (B - A)$$

$$P(A \cup B) = P(A \cap B) + P(A - B) + P(B - A)$$



$$A = A \cap S = A \cap (B \cup B') = (A \cap B) \cup (A \cap B')$$

$$A-B=A\bigcap B'$$
.

$$P(A) = P(A \cap B) + P(A - B)$$

$$P(A-B) = P(A) - P(A \cap B)$$
 Podobnie

$$P(B-A) = P(B) - P(A \cap B)$$

Podstawiając prawe strony powyższych dwu równości do równości w ramce otrzymujemy tezę twierdzenia.



# Prawdopodobieństwo warunkowe

$$S = \{s_1, s_2, ..., s_M\}, P(\{s_i\}) = \frac{1}{M}, i = 1, 2, ..., M,$$

- $A \subset S, B \subset S,$
- $n(A), n(B), n(A \cap B)$  liczności zdarzeń sprzyjających

$$\frac{n(A \cap B)}{n(A)} = \frac{n(A \cap B) / n(S)}{n(A) / n(S)} = \frac{P(A \cap B)}{P(A)}$$

$$P(B|A) = \frac{P(A|B)}{P(A)} - \text{prawdopodobieństwo}$$

warunkowe zajścia zdarzenia B pod warunkiem zajścia A.



## Definicja 6

Niech  $A \subset S$  i  $B \subset S$ , P(A) > 0.

Prawdopodobieństwo warunkowe zdarzenia  $\it B$  pod warunkiem zajścia zdarzenia  $\it A$  dane jest wzorem

$$P(B|A) = \frac{P(A \cap B)}{P(A)}$$



#### **Przykład**

Obliczono, że 70% studentów zdało egzamin z matematyki w czasie sesji, natomiast 30% zdało egzamin z matematyki i angielskiego. Jakie jest prawdopodobieństwo, że student, który zdał egzamin z matematyki zdał również egzamin z angielskiego?

#### Rozwiązanie.

Niech A = "losowo wybrany student zdał matematykę",

B = "losowo wybrany student zdał angielski".

$$P(B|A) = \frac{P(A \cap B)}{P(A)} = \frac{0.3}{0.7} = \frac{3}{7}$$



#### Twierdzenie 4

Niech 
$$A \subset S$$
 i  $B \subset S$ , oraz  $P(A) > 0$  i  $P(B) > 0$ . Wówczas 
$$P(A \cap B) = P(B|A)P(A) = P(A|B)P(B).$$

#### **Przykład**

Urna zawiera 6 kul czarnych i 4 białe. Losujemy 2 kule bez zwracania. Niech

```
A = \{ \ 2 \ \text{kule czarne} \ \}, B = \{ \ 1 \ \text{kula czarna} \ i \ 1 \ \text{kula biała} \ \}. C_i = \{ \ \text{w} \ i\text{-tym ciągnieniu kula czarna} \ \}, B_i = \{ \ \text{w} \ i\text{-tym ciągnieniu kula biała} \}, \ i = 1, 2.
```



$$P(A) = P(C_1 \cap C_2) = P(C_1)P(C_2|C_1) = \frac{6}{10} \times \frac{5}{9} = \frac{1}{3},$$

$$P(B) = P[(B_1 \cap C_2) \cup (C_1 \cap B_2)] = P(B_1 \cap C_2) + P(C_1 \cap B_2) =$$

$$P(C_2|B_1)P(B_1) + P(B_2|C_1)P(C_1) = \frac{6}{9} \times \frac{4}{10} + \frac{4}{9} \times \frac{6}{10} = \frac{8}{15}.$$

$$P(A) = \frac{\binom{6}{2}}{\binom{10}{2}} = \frac{1}{3}, \qquad P(B) = \frac{\binom{6}{4}\binom{4}{1}}{\binom{10}{2}} = \frac{8}{15}.$$



# Reguła wielokrotnego warunkowania

$$P(A \cap B \cap C) = P[C \cap (A \cap B)] =$$

$$P(C|A \cap B)P(A \cap B) =$$

$$P(C|A \cap B)P(B|A)P(A)$$

#### Dla k zdarzeń losowych:

$$P(A_1 \cap A_2 \cap ... \cap A_k) = P(A_k | A_{k-1} \cap A_{k-2} \cap ... \cap A_1) \times$$
$$\times P(A_{k-1} | A_{k-2} \cap ... \cap A_1) \times ... \times P(A_2 | A_1) \times P(A_1).$$



## Przykład (drzewa prawdopodobieństw warunkowych)

Pewna uczelnia bada wyniki nauczania.

```
A_1 = {po I sem. ocena > 3 z przedm. ogólnych}
A_2 = \{\text{po II sem. ocena} > 4 \text{ z przedm. specjalist.}\}
B = \{ "dobre" ukończenie studiów \}
C = { "słabsze" ukończenie studiów }
D = { nieukończenie studiów }
P(A_1) = 0.76, P(A_2'|A_1) = 0.80, P(C|A_1 \cap A_2') = 0.69.
    P(A_1 \cap A_2' \cap C) = 0.76 \times 0.80 \times 0.69 = 0.42.
```



#### **Uwaga:**

Niech  $A \subset S$ , P(A) > 0. Prawdopodobieństwo warunkowe pod warunkiem zdarzenia A spełnia aksjomaty prawdopodobieństwa z definicji 5, jeli zamienimy S na A:

- $\blacksquare 0 \le P(B|A) \le 1$ , dla każdego zdarzenia B,
- $P(A|A) = 1, P(\emptyset|A) = 0,$
- Jeśli zdarzenia  $B_1, B_2, B_3, ...$  wykluczają się wzajemnie , to

$$P(B_1 \cup B_2 \cup B_3 \cup ... | A) = P(B_1 | A) + P(B_2 | A) + P(B_3 | A) + ...$$



## Zdarzenia niezależne

Prawdopodobieństwo warunkowe pozwala określić niezależność zdarzeń. Zdarzenia  $A \in B$ , o dodatnich prawdopodobieństwach, nazwiemy niezależnymi, jeśli informacja o zajściu jednego z nich nie wpływa na prawdopodobieństwo zajścia drugiego:

$$P(B|A) = P(B)$$
 oraz  $P(A|B) = P(A)$ 



## Zdarzenia niezależne

## Definicja.

Zdarzenia A i B nazywamy niezależnymi, jeśli

$$P(A \cap B) = P(A)P(B)$$
.

Zdarzenia  $A_1, A_2, ..., A_k$ ,  $k \ge 2$ , nazywamy **niezależnymi**, jeśli dla każdego m,  $2 \le m \le k$ , dla dowolnych różnych zdarzeń  $A_{i_1}, A_{i_2}, ..., A_{i_m}$  z rodziny  $\{A_1, A_2, ..., A_k\}$ :

$$P(A_{i_1} \cap A_{i_2} \cap ... \cap A_{i_m}) = P(A_{i_1}) \times ... \times P(A_{i_m})$$



# Zdarzenia niezależne parami

## Określenie.

Zdarzenia  $A_1,A_2,...,A_k$ ,  $k\geq 2$ , nazywamy niezależnymi parami, jeśli każde dwa zdarzenia spośród nich są niezależne.

<u>Uwaga</u>: Z niezależności parami nie wynika niezależność rodziny zdarzeń  $A_1,A_2,...,A_k$ .

Natomiast niezależność rodziny zdarzeń implikuje niezależność parami.



# Zdarzenia niezależne parami

**Przykład.** Urna zawiera 4 kule – zieloną, niebieską, czerwoną i kulę zielono-niebiesko-czerwoną. Niech

 $A_1$  = { w losowo wybranej kuli jest kolor zielony },

 $A_2$  = { w losowo wybranej kuli jest kolor niebieski },

 $A_3$  = { w losowo wybranej kuli jest kolor czerwony },

 $B = \{ losowo wybrana kula jest trójkolorowa \}.$ 

Pokaż, że zdarzenia  $A_1,A_2,A_3$  nie są niezależne, ale są parami niezależne.

Wsk. 
$$A_1 \cap A_2 = A_2 \cap A_3 = A_1 \cap A_3 = B$$
.

**Przykład.** Niech  $S = \{s_1, s_2, s_3, s_4\}$  oraz zdarzenia elementarne są jednakowo prawdopodobne.

$$\Box$$
  $A_1 = \{s_1, s_2\}, A_2 = \{s_1, s_3\}, A_3 = \{s_1, s_4\}$ 

•  $A_1, A_2, A_3$  są niezależne parami, ale

$$P(A_1 \cap A_2 \cap A_3) = 0.25 \neq P(A_1)P(A_2)P(A_3) = 0.125.$$

$$\Box$$
  $B_1 = \{s_1\}, B_2 = \{s_1, s_2\}, B_3 = \emptyset.$ 

•  $B_1, B_2, B_3$  nie są parami niezależne, ale  $P(B_1 \cap B_2 \cap B_3) = P(B_1)P(B_2)P(B_3)$ .



## Niezależność układu zdarzeń

**Przykład.** Układ czterech przekaźników połączony jest w taki sposób, że: dwa pierwsze – szeregowo, połączone są szeregowo z dwoma pozostałymi połączonymi równolegle. Przekaźniki pracują niezależnie, prawdopodobieństwo awarii każdego z nich wynosi 0,1. Oblicz niezawodność układu przekaźników, tzn. prawdopodobieństwo poprawnej pracy.

- $A_i = \{ \text{ przekaźnik i pracuje poprawnie } \}, i = 1,2,3,4.$
- ◆ D = { układ pracuje poprawnie } =

$$A_1 \cap A_2 \cap (A_3 \cup A_4)$$

$$D = (A_1 \cap A_2 \cap A_3) \cup (A_1 \cap A_2 \cap A_4).$$



## Niezależność układu zdarzeń

$$D = (A_1 \cap A_2 \cap A_3) \cup (A_1 \cap A_2 \cap A_4).$$

Z twierdzenia 3 ( prawdopodobieństwo sumy zdarzeń) oraz definicji 7 ( niezależność zdarzeń ):

#### Niezawodność =

$$P(D) = P(A_1 \cap A_2 \cap A_3) + P(A_1 \cap A_2 \cap A_4) +$$

$$-P(A_1 \cap A_2 \cap A_3 \cap A_4) = 0.9^3 + 0.9^3 - 0.9^4 =$$

$$0,8019.$$



# Zupełny układ zdarzeń

## Definicja 8.

Zdarzenia  $B_1, B_2, ..., B_k$  tworzą **podział** przestrzeni zdarzeń elementarnych S ( układ **zupełny** zdarzeń ), jeśli  $B_i \cap B_j = \emptyset$  dla  $i \neq j$ , oraz

$$B_1 \cup B_2 \cup ... \cup B_k = S$$
.



# Prawdopodobieństwo całkowite

#### Twierdzenie 5. ( o prawdopodobieństwie całkowitym).

Jeśli  $B_1, B_2, ..., B_k$  tworzą **układ zupełny** zdarzeń oraz  $P(B_i) \neq 0$ , i = 1, 2, ... k, to dla każdego zdarzenia A:

$$P(A) = \sum_{i=1}^{k} P(A \cap B_i) = \sum_{i=1}^{k} P(A|B_i)P(B_i)$$

$$\mathbf{D}. P(A) = P(A \cap S) = P(A \cap (B_1 \cup B_2 \cup ... \cup B_k)) =$$

$$P((A \cap B_1) \cup (A \cap B_2) \cup ... \cup (A \cap B_k)) =$$

$$\sum_{i=1}^{k} P(A \cap B_i) = \sum_{i=1}^{k} P(A|B_i)P(B_i).$$



# Twierdzenie Bayesa

<u>Twierdzenie 6.</u> ( **reguła Bayesa'a** ). Jeśli zdarzenia  $B_1, B_2, ..., B_k$  tworzą podział przestrzeni S oraz  $P(B_i) > 0$ , i = 1, 2, ..., k, to dla  $A \in S$ , takiego że P(A) > 0,

$$P(B_m|A) = \frac{P(A|B_m)P(B_m)}{P(A)} = \frac{P(A|B_m)P(B_m)}{\sum_{j=1}^k P(A|B_j)P(B_j)},$$

gdzie  $B_m$  jest dowolnym ustalonym zdarzeniem spośród zdarzeń  $B_1, B_2, ..., B_k$ ,  $1 \le m \le k$ .



# Reguła Bayesa

**Przykład.** W konferencji naukowej bierze udział 30 % matematyków i 70 % informatyków. Wśród matematyków jest 50 % kobiet a wśród informatyków zaledwie 10 % stanowią kobiety. Wybrana losowo osoba jest (a) kobietą , (b) mężczyzną. Jakie jest prawdopodobieństwo, że wybrana osoba jest matematykiem ?

Określamy zdarzenia:

 $A = \{ wybrana losowo osoba jest kobietą \},$ 

 $B_1 = \{ \text{ wybrana losowo osoba jest matematykiem} \},$ 

 $B_2 = \{ \text{ wybrana losowo osoba jest informatykiem} \},$ 

$$P(B_1) = 0.3$$
,  $P(B_2) = 0.7$ ,  $P(A|B_1) = 0.5$ ,  $P(A|B_2) = 0.1$ ,

$$P(A'|B_1) = 1 - P(A|B_1) = 1 - 0.5 = 0.5,$$
  
 $P(A'|B_2) = 1 - P(A|B_2) = 1 - 0.1 = 0.9.$ 



# Reguła Bayesa

$$P(B_1) = 0.3$$
,  $P(B_2) = 0.7$ ,  $P(A|B_1) = 0.5$ ,  $P(A|B_2) = 0.1$ ,  $P(A'|B_1) = 1 - P(A|B_1) = 1 - 0.5 = 0.5$ ,  $P(A'|B_2) = 1 - P(A|B_2) = 1 - 0.1 = 0.9$ .

(a)

$$P(B_1|A) = \frac{P(A|B_1)P(B_1)}{P(A|B_1)P(B_1) + P(A|B_2)P(B_2)} =$$

$$= \frac{0.5 \times 0.3}{0.5 \times 0.3 + 0.1 \times 0.7} \approx 0.68.$$



# Reguła Baeysa

## **Interpretacja:**

Wśród matematyków jest dużo kobiet, zatem prawdop., że wybrana osoba jest matematykiem zwiększyło się, jeśli wiemy, że ta osoba jest kobietą.

$$P(B_1) = 0.3$$

$$P(B_1|A) = 0.68$$

$$P(B_1) = 0.3$$

$$P(B_1|A') = 0.19$$



# Reguła Bayesa

$$P(B_1) = 0.3$$
,  $P(B_2) = 0.7$ ,  $P(A|B_1) = 0.5$   
 $P(A|B_2) = 0.1$ ,

$$P(A'|B_1) = 1 - P(A|B_1) = 1 - 0.5 = 0.5,$$
  
 $P(A'|B_2) = 1 - P(A|B_2) = 1 - 0.1 = 0.9.$ 

(b)

$$P(B_1|A') = \frac{P(A'|B_1)P(B_1)}{P(A'|B_1)P(B_1) + P(A'|B_2)P(B_2)} =$$

$$= \frac{0.5 \times 0.3}{0.5 \times 0.3 + 0.9 \times 0.7} \approx 0.19.$$





Dziękuję za uwagę