



Statystyczna analiza danych SAD-2020/2021

Wykład 6

Dwuwymiarowe zmienne losowe

$$X: S \rightarrow (-\infty, \infty), \quad Y: S \rightarrow (-\infty, \infty)$$

- (X, Y) – para zmiennych losowych
(dwuwymiarowa zmienna losowa, wektor losowy 2-wymiarowy)
- Zmienną losową X nazywamy brzegową zmienną losową, podobnie Y nazywamy brzegową zmienną losową

Przykłady:

- Wzrost, Waga losowo wybranej osoby z pewnej populacji

Dwuwymiarowe zmienne losowe

- Miesięczny dochód pracownika, Miesięczny dochód firmy
- Temperatura, Zużycie energii na klimatyzację

Problemy:

- Wyznaczenie rozkładu prawdopodobieństwa łącznego zmiennej l. (X, Y)
- Wyznaczenie rozkładów prawdopodobieństwa brzegowych zmiennych losowych na podstawie rozkładu łącznego

Dwuwymiarowe zmienne losowe

- Charakterystyki liczbowe określające stopień współzależności między zmiennymi X , Y
- Określenie niezależności zmiennych losowych
- Warunkowe rozkłady prawdopodobieństwa jednej ze zmiennych pod warunkiem, że druga przyjęła konkretną wartość

Przykład. Wyznaczyć funkcję prawdopodobieństwa łącznego pary (X, Y) , gdzie X przyjmuje wartość 1 (0) jeśli wypadł orzeł (reszka) w pierwszym rzucie monetą, a Y jest liczbą orłów w pierwszym i drugim rzucie monetą.



Dwuwymiarowy wektor losowy

Niech 1 – wyrzucenie orła, 0 – wyrzucenie reszki

s	$X(s)$	$Y(s)$
$(0,0)$	0	0
$(0,1)$	0	1
$(1,0)$	1	1
$(1,1)$	1	2



Dwuwymiarowy wektor losowy

Funkcja prawdopodobieństwa łącznego:

$$f(x, y) := P(X = x, Y = y)$$

określona jest tablicą kontyngencyjną

y	0	1	2
x			
0	$1/4$	$1/4$	0
1	0	$1/4$	$1/4$



Dwuwymiarowe zmienne losowe

Rozkład łączny pary zmiennych losowych (X, Y) określonych na tej samej przestrzeni zdarzeń elementarnych:

$P((X, Y) \in A)$, A - dowolny podzbiór zbioru par wartości zmiennych X, Y .

Definicja. Dystrybuantą zmiennej losowej (X, Y) nazywamy funkcję

$$F(x, y) = P(X \leq x, Y \leq y),$$

gdzie $-\infty < x < \infty, -\infty < y < \infty$.



Dwuwymiarowe zmienne losowe

Twierdzenie. Łączny rozkład prawdopodobieństwa zmiennej losowej (X, Y) określony jest jednoznacznie przez jej dystrybuantę.

Dyskretne zmienne losowe

Funkcja prawdopodobieństwa (łącznego)
dwuwymiarowej zmiennej losowej dyskretnej:

$$f(x, y) = P(X = x, Y = y).$$

Dwuwymiarowe zmienne losowe

Własności:

$$\square f(x, y) \geq 0, \text{ dla dowolnej pary wartości } (x, y),$$

$$\square \sum_x \sum_y f(x, y) = 1,$$

$$\square P((X, Y) \in A) = \sum_{(x, y) \in A} f(x, y),$$

$$\square F(x, y) = \sum_{s \leq x} \sum_{t \leq y} f(s, t).$$



Dwuwymiarowe zmienne losowe

Notacja.

Niech x_1, x_2, \dots, x_r będą wartościami zmiennej losowej X , a y_1, y_2, \dots, y_s będą wartościami zmiennej losowej Y

$$p_{ij} := P(X = x_i, Y = y_j), \quad i = 1, \dots, r, j = 1, \dots, s$$

Tablica kontyngencyjna

j	1	2	s
i					
1	p_{11}	p_{12}		p_{1s}
2	p_{21}	p_{22}		p_{2s}
.					
.					
.					
r	p_{r1}	p_{r2}		p_{rs}

Całka podwójna

$D := \{(x, y): a \leq x \leq b, c \leq y \leq d\}$ – prostokąt

$$D = [a, b] \times [c, d]$$

$$\iint_D f(x, y) dx dy = \int_a^b \left(\int_c^d f(x, y) dy \right) dx$$

Obliczanie całki podwójnej

Przykład. Niech $D = [0,1] \times [2,3]$

$$\begin{aligned} \iint_D xy dx dy &= \int_0^1 \left(\int_2^3 xy dy \right) dx = \\ &= \int_0^1 x \left(\int_2^3 y dy \right) dx = \int_0^1 x \left(\frac{y^2}{2} \Big|_2^3 \right) dx = \\ &= \left(\frac{3^2}{2} - \frac{2^2}{2} \right) \int_0^1 x dx = \frac{5}{2} \frac{x^2}{2} \Big|_0^1 = \frac{5}{4} \end{aligned}$$

Obliczanie całki podwójnej

Niech $D = (-\infty, x] \times (-\infty, y]$

$$\begin{aligned}\iint_D f(x, y) dx dy &= \int_{-\infty}^x \left(\int_{-\infty}^y f(x, y) dy \right) dx = \\ &= \lim_{a \rightarrow \infty, c \rightarrow \infty} \int_a^x \left(\int_c^y f(x, y) dy \right) dx\end{aligned}$$



Wektor losowy typu ciągłego

Dwuwymiarowa zmienna losowa (X, Y) jest ciągłą zmienną losową, jeśli jej **łączny rozkład prawdopodobieństwa** określony jest przez **funkcję gęstości (łączną gęstość prawdopodobieństwa)**:

$$P((X, Y) \in A) = \iint_A f(x, y) dx dy$$

Dla $A = (-\infty, x] \times (-\infty, y]$:

$$F(x, y) = P(X \leq x, Y \leq y) = \int_{-\infty}^x \int_{-\infty}^y f(s, t) dt ds.$$



Łączna gęstość prawdopodobieństwa

Własności gęstości

$$\square f(x, y) \geq 0$$

$$\square \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1$$

$$\square f(x, y) = \frac{\partial^2}{\partial x \partial y} F(x, y), \quad -\infty < x < \infty, \quad -\infty < y < \infty.$$

Łączna gęstość prawdopodobieństwa

Przykład

$$f(x, y) = \begin{cases} Cx & \text{dla } (x, y) \in [0, 1] \times [0, 2] \\ 0 & \text{dla } (x, y) \notin [0, 1] \times [0, 2] \end{cases}$$

Wyznaczyć: a) stałą C , $F\left(\frac{1}{2}, \frac{1}{2}\right)$, $F\left(\frac{3}{2}, 1\right)$

b) $P\left(X > \frac{1}{2}, Y \leq \frac{3}{4}\right)$

$$1 = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = \iint_{[0, 1] \times [0, 2]} Cx dx dy$$

Łączna gęstość prawdopodobieństwa

$$\iint_{[0,1] \times [0,2]} Cx dx dy = \int_0^1 \left(\int_0^2 Cx dy \right) dx = \int_0^1 Cx \left(\int_0^2 dy \right) dx$$

$$= C \cdot 2 \cdot \frac{x^2}{2} \Big|_0^1 = 2C \left(\frac{1^2}{2} - \frac{0^2}{2} \right) = C \implies C = 1$$

$$F\left(\frac{1}{2}, \frac{3}{2}\right) = P\left(X \leq \frac{1}{2}, Y \leq \frac{3}{2}\right) = \int_{-\infty}^{\frac{1}{2}} \left(\int_{-\infty}^{\frac{3}{2}} f(x, y) dy \right) dx =$$

Łączna gęstość prawdopodobieństwa

$$F\left(\frac{1}{2}, \frac{3}{2}\right) = \int_0^{\frac{1}{2}} \left(\int_0^{\frac{3}{2}} x dy \right) dx = \int_0^{\frac{1}{2}} x \cdot \frac{3}{2} dx = \frac{3}{2} \frac{x^2}{2} \Big|_0^1 = \frac{3}{4}$$

$$F\left(\frac{3}{2}, 1\right) = \int_0^1 \left(\int_0^1 x dy \right) dx = \int_0^1 x \left(\int_0^1 dy \right) dx = \frac{x^2}{2} \Big|_0^1 = \frac{1}{2}$$

Łączna gęstość prawdopodobieństwa

$$\begin{aligned}
 P\left(X > \frac{1}{2}, Y \leq \frac{3}{4}\right) &= \int_{\frac{1}{2}}^1 \left(\int_0^{\frac{3}{4}} x dy \right) dx = \int_{\frac{1}{2}}^1 x \cdot \frac{3}{4} dx = \\
 &= \frac{3}{4} \frac{x^2}{2} \Big|_{\frac{1}{2}}^1 = \frac{3}{4} \left(\frac{1^2}{2} - \frac{\left(\frac{1}{2}\right)^2}{2} \right) = \frac{9}{32}
 \end{aligned}$$



Brzegowe rozkłady prawdopodobieństwa

Niech (X, Y) będzie dwuwymiarową zmienną losową o rozkładzie prawdopodobieństwa określonym przez funkcję $f(x, y)$ (funkcja prawdopodobieństwa lub gęstość).

Rozkład brzegowy = rozkład prawdopodobieństwa zmiennej losowej X lub zmiennej losowej Y .



Brzegowe rozkłady prawdopodobieństwa

□ dla **dyskretnej** zmiennej (X, Y) , **brzegowe funkcje prawdopodobieństwa** są postaci

$$f_X(x) = P(X = x) = \sum_y f(x, y)$$

$$f_Y(y) = P(Y = y) = \sum_x f(x, y)$$

□ dla **ciągłej** zmiennej (X, Y) , **brzegowe gęstości** są postaci

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy, \quad f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx.$$

Brzegowa funkcja prawdopodobieństwa

Przykład. (c.d. str. 4-6)

y	0	1	2	$f_X(x) = P(X = x)$
x				
0	1/4	1/4	0	1/2
1	0	1/4	1/4	1/2
$f_Y(y) = P(Y = y)$	1/4	2/4	1/4	1

np

$$f_X(0) = f(0,0) + f(0,1) + f(0,2) = 1/2$$

$$f_Y(1) = f(0,1) + f(1,1) = 2/4$$



Rozkłady brzegowe w tablicy kontyngencyjnej

$$p_{ij} := P(X = x_i, Y = y_j), \quad i = 1, \dots, r, j = 1, \dots, s$$

$$p_{i.} := P(X = x_i)$$

$$p_{.j} := P(Y = y_j)$$

$$p_{i.} = p_{i1} + p_{i2} + \dots + p_{is}, \quad i = 1, 2, \dots, r$$

$$p_{.j} = p_{1j} + p_{2j} + \dots + p_{rj}, \quad j = 1, 2, \dots, s$$

Rozkłady brzegowe w tablicy kontyngencyjnej

$$p_{ij} := P(X = x_i, Y = y_j), \quad i = 1, \dots, r, j = 1, \dots, s$$

j	1	2	s	
i						$p_{i\cdot}$
1	p_{11}	p_{12}		p_{1s}	$p_{1\cdot}$
2	p_{21}	p_{22}		p_{2s}	$p_{2\cdot}$
.						
.						
r	p_{r1}	p_{r2}		p_{rs}	$p_{r\cdot}$
$p_{\cdot j}$	$p_{\cdot 1}$	$p_{\cdot 2}$		$p_{\cdot s}$	1

Przykład. $f(x, y) = \begin{cases} x & \text{dla } (x, y) \in [0, 1] \times [0, 2] \\ 0 & \text{dla } (x, y) \notin [0, 1] \times [0, 2] \end{cases}$

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy$$

Należy rozważyć 2 przypadki

$$1) \ x \notin [0, 1] \Rightarrow f_X(x) = \int_{-\infty}^{\infty} 0 dy = 0$$

$$2) \ x \in [0, 1] \Rightarrow f_X(x) = \int_0^2 x dy = 2x$$

Przykład. $f(x, y) = \begin{cases} x & \text{dla } (x, y) \in [0, 1] \times [0, 2] \\ 0 & \text{dla } (x, y) \notin [0, 1] \times [0, 2] \end{cases}$

$$f_X(x) = \begin{cases} 2x & \text{dla } x \in [0, 1] \\ 0 & \text{dla } x \notin [0, 1] \end{cases}$$

Podobnie znajdziemy gęstość zmiennej brzegowej Y .

$$f_Y(y) = \begin{cases} 1/2 & \text{dla } y \in [0, 2] \\ 0 & \text{dla } y \notin [0, 2] \end{cases}$$

$$Y \sim U(0, 2)$$

Warunkowe rozkłady prawdopodobieństwa

□ Niech $f(x, y)$ funkcja prawdopodobieństwa **dyskretnej** zmiennej losowej (X, Y) , y – ustalone, $f_Y(y) > 0$.

Rozkład warunkowy zmiennej losowej X pod warunkiem, że $Y = y$ określa **warunkowa funkcja prawdopodobieństwa**:

$$f(x|y) = \frac{f(x, y)}{f_Y(y)}, \quad x - \text{dowolna wartość zmiennej } X.$$

$$f(x|y) = \frac{P(X = x, Y = y)}{P(Y = y)} = P(X = x|Y = y)$$

Warunkowe rozkłady prawdopodobieństwa

Analogicznie:

$$f(y|x) = \frac{f(x, y)}{f_X(x)} = P(Y = y | X = x), \text{ gdzie } f_X(x) > 0,$$

y - dowolna wartość Y

Notacja:

$$f(x|y) = f_{X|Y}(x|y)$$

$$f(y|x) = f_{Y|X}(y|x)$$



Warunkowa funkcja prawdopodobieństwa

Przykład. (kontynuacja, SADW06) Zmienne losowe X , Y oznaczają liczby punktów uzyskane w etapie I i II, odpowiednio, przez losowo wybranego uczestnika teleturnieju.

- ☐ Znaleźć **rozkład brzegowy zmiennej Y** , liczby punktów uzyskanych w II etapie teleturnieju, przez losowo wybranego uczestnika.
- ☐ Wyznaczyć **rozkład warunkowy Y pod warunkiem, że w I etapie uzyskano 2 punkty, tzn. $X = 2$.**

Warunkowa funkcja prawdopodobieństwa

Y	0	1	2
X			
0	0,50	0,05	0,01
1	0,20	0,10	0,06
2	0,02	0,03	0,03

□ $f_Y(y) = f(0, y) + f(1, y) + f(2, y)$. Stąd

y	0	1	2
$f_Y(y)$	0,72	0,18	0,1

□ $f(y|2) = f_{Y|X}(y|2) = \frac{f(2, y)}{f_X(2)} = \frac{f(2, y)}{0,08} = ?$

y	0	1	2
$f(y 2)$	$\frac{0,02}{0,08} = 2/8$	$\frac{0,03}{0,08} = 3/8$	$\frac{0,03}{0,08} = 3/8$



Warunkowa gęstość prawdopodobieństwa

Niech $f(x, y)$ - łączna gęstość **ciągłej** zmiennej losowej (X, Y) , y – ustalone: $f_Y(y) > 0$

Warunkową gęstością prawdopodobieństwa zmiennej losowej X pod warunkiem, że $Y = y$ nazywamy funkcję

$$f(x|y) = \frac{f(x, y)}{f_Y(y)}, \quad x \in (-\infty, \infty)$$

Notacja: $f(x|y) = f_{X|Y}(x|y)$

Niech $f(x, y)$ - łączna gęstość **ciągłej** zmiennej losowej (X, Y) , x – ustalone: $f_X(x) > 0$

Warunkową gęstością prawdopodobieństwa zmiennej losowej Y pod warunkiem, że $X = x$ nazywamy funkcję

$$f(y|x) = \frac{f(x, y)}{f_X(x)}, \quad y \in (-\infty, \infty)$$

Notacja: $f(y|x) = f_{Y|X}(y|x)$

Niezależne zmienne losowe

Definicja. Niech (X, Y) będzie dwuwymiarową zmienną losową o dystrybuancie $F(x, y)$ oraz dystrybuantach brzegowych $F_X(x)$, $F_Y(y)$, $x, y \in (-\infty, \infty)$.

Zmienne losowe **X, Y są niezależne**, jeśli

$$F(x, y) = F_X(x)F_Y(y),$$

dla wszystkich wartości x, y .

Niezależne zmienne losowe

Zmienne losowe X, Y są niezależne \Leftrightarrow
dla dowolnych $x \in (-\infty, \infty)$, $y \in (-\infty, \infty)$
zdarzenia

$\{X \leq x\}$, $\{Y \leq y\}$ są niezależne

Zmienne losowe są zależne, jeśli nie są
niezależne

Niezależne zmienne losowe

Twierdzenie.

Zmienne losowe **X, Y** są **niezależne** wtedy i tylko wtedy gdy dla wszystkich wartości x, y .

$$f(x, y) = f_X(x)f_Y(y)$$

Wniosek. Poniższe warunki są równoważne:

- Zmienne losowe **X, Y** są **niezależne**.
- Rozkłady warunkowe są takie jak rozkłady brzegowe

Niezależne zmienne losowe

Wniosek. Poniższe warunki są równoważne:

- Zmienne losowe **X, Y** są **niezależne**.
- $f_{X|Y}(x|y) = f_X(x)$, x - dowolne, y - takie że $f_Y(y) > 0$.
- $f_{Y|X}(y|x) = f_Y(y)$, y - dowolne, x - takie że $f_X(x) > 0$.

Przykład. (kontynuacja) Czy liczby punktów uzyskane w I i II etapie teleturnieju przez losowo wybranego uczestnika są niezależnymi zmiennymi losowymi ?

Y X	0	1	2
0	0,50	0,05	0,01
1	0,20	0,10	0,06
2	0,02	0,03	0,03

$$f_X(0) = f(0,0) + f(0,1) + f(0,2) = 0,5 + 0,05 + 0,01 = 0,56.$$

$$f_Y(0) = f(0,0) + f(1,0) + f(2,0) = 0,5 + 0,2 + 0,02 = 0,72.$$

$$f(0,0) = 0,5 \neq 0,56 \times 0,72 = f_X(0)f_Y(0)$$

Zmienne losowe X, Y są **zależne**.

Przykład. Czy X, Y są **niezależnymi** zmiennymi losowymi, jeśli ich łączna gęstość ma postać:

$$f(x, y) = \begin{cases} 3(x - y)^2 / 8 & \text{gdy } -1 \leq x \leq 1, -1 \leq y \leq 1 \\ 0 & \text{przeciwnie} \end{cases}$$

Dla $x, y \in [-1, 1]$:

$$f_X(x) = (3x^2 + 1) / 4 \quad \text{oraz} \quad f_Y(y) = (3y^2 + 1) / 4.$$

$$f(x, y) \neq f_X(x)f_Y(y).$$

X, Y są zależne.

Przykład. Czasy poprawnej pracy dwu podzespołów są **niezależnymi** zmiennymi losowymi **X, Y** o rozkładach **wykładniczych** z parametrami λ_1, λ_2 , odpowiednio.

Średnie czasy pracy podzespołów wynoszą 1000 (godzin) i 1200 (godzin). Obliczyć prawdopodobieństwo zdarzenia takiego, że żaden podzespół nie ulegnie awarii przed upływem 1500 godzin.

$$E(X) = 1/\lambda_1 = 1000 \text{ (godz.)}, E(Y) = 1/\lambda_2 = 1200 \text{ (godz.)}$$

Stąd $\lambda_1 = 1/1000$ (1/godz.) $\lambda_2 = 1/1200$ (1/godz.).

$$\begin{aligned} P(X \geq 1500, Y \geq 1500) &= P(X \geq 1500) P(Y \geq 1500) = \\ e^{-\lambda_1 1500} \times e^{-\lambda_2 1500} &= e^{-1500/1000} \times e^{-1500/1200} = \\ &= 0,2231 \times 0,2865 = 0,0639. \end{aligned}$$

Wartość oczekiwana. Kowariancja.

□
$$E[g(X, Y)] = \sum_x \sum_y g(x, y) f(x, y),$$

gdzie (X, Y) - **dyskretna**,

□
$$E[g(X, Y)] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) f(x, y) dx dy,$$

gdzie (X, Y) - **ciągła**.

Uwaga. Dla $g(X, Y) = X$ lub $g(X, Y) = Y$ otrzymujemy wartości oczekiwane brzegowych zmiennych losowych X lub Y , gdyż

Wartość oczekiwana

Przykład.

y	0	1	2
x			
0	1/4	1/4	0
1	0	1/4	1/4

$$\begin{aligned}
 E(XY) &= \sum_x \sum_y xyf(x, y) = 0 \cdot 0 \cdot \frac{1}{4} + 0 \cdot 1 \cdot \frac{1}{4} + 0 \cdot 2 \cdot 0 + \\
 &\quad + 1 \cdot 0 \cdot 0 + 1 \cdot 1 \cdot \frac{1}{4} + 1 \cdot 2 \cdot \frac{1}{4} = \frac{3}{4}
 \end{aligned}$$

□ w przypadku **dyskretnym**:

$$E(X) = \sum_x \sum_y x f(x, y) = \sum_x x \sum_y f(x, y) = \sum_x x f_X(x) = \mu_X.$$

$$E(Y) = \sum_x \sum_y y f(x, y) = \sum_y y \sum_x f(x, y) = \sum_y y f_Y(y) = \mu_Y$$

□ w przypadku **ciągłym**:

$$E(X) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x f(x, y) dx dy =$$

$$\int_{-\infty}^{\infty} x \left(\int_{-\infty}^{\infty} f(x, y) dy \right) dx = \int_{-\infty}^{\infty} x f_X(x) dx = \mu_X.$$

Analogicznie:

$$E(Y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} yf(x, y)dx dy = \int_{-\infty}^{\infty} yf_Y(y)dy = \mu_Y.$$

Stwierdzenie. Niech c będzie dowolną stałą, a $g(X, Y)$, $g_1(X, Y)$, $g_2(X, Y)$ zmiennymi losowymi jednowymiarowymi.

□ $E[cg(X, Y)] = cE[g(X, Y)]$

□ $E[g_1(X, Y) + g_2(X, Y)] = E[g_1(X, Y)] + E[g_2(X, Y)]$

Stwierdzenie.

Jeśli zmienne losowe X , Y są niezależne, to

$$E(XY) = E(X)E(Y).$$

D. Niezależność zmiennych jest równoważna

$f(x, y) = f_X(x)f_Y(y)$. Stąd i z definicji wartości średniej:

□ (zmienne dyskretne)

$$E[g(X, Y)] = \sum_x \sum_y g(x, y) f(x, y).$$

$$E(XY) = \sum_x \sum_y xyf(x, y) = \sum_x \sum_y xyf_X(x)f_Y(y) =$$

$$\sum_x xf_X(x) \sum_y yf_Y(y) = \sum_y yf_Y(y) \times \sum_x xf_X(x) =$$

$$E(Y)E(X) = E(X)E(Y).$$

□ (zmienne ciągłe) Dowód analogiczny - sumowanie należy zastąpić całkowaniem.

Definicja. Niech X i Y będą zmiennymi losowymi o łącznej funkcji prawdopodobieństwa (gęstości) $f(x, y)$.

Kowariancją zmiennych X i Y nazywamy liczbę

$$\sigma_{XY} = E[(X - \mu_X)(Y - \mu_Y)].$$

Uwaga. Z definicji σ_{XY} oraz $E[g(X, Y)]$, przyjmując $g(x, y) = (x - \mu_X)(y - \mu_Y)$, otrzymujemy:



$$\sigma_{XY} = \sum_x \sum_y (x - \mu_X)(y - \mu_Y) f(x, y) \quad , \text{ gdy } (X, Y) - \text{ dyskretna}$$

$$\sigma_{XY} = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - \mu_X)(y - \mu_Y) f(x, y) dx dy \quad , \text{ gdy } (X, Y) - \text{ ciągła}$$

Interpretacja. Kowariancja określa pewną **współzależność** między zmiennymi losowymi:

- ❑ Jeśli „dużym” wartościom zmiennej X przewyższającym μ_X towarzyszą zwykle „duże” wartości zmiennej Y przewyższające μ_Y , a wartościom X mniejszym od μ_X towarzyszą zwykle wartości Y mniejsze od μ_Y , to $\sigma_{XY} > 0$
- ❑ Jeśli wartościom zmiennej X większym od μ_X towarzyszą zwykle wartości Y mniejsze od μ_Y wartościom X mniejszym od μ_X towarzyszą zwykle wartości Y większe od μ_Y , to $\sigma_{XY} < 0$

Notacja: Zamiast σ_{XY} często piszemy **Cov (X,Y).**



Stwierdzenie.

$$\mathbf{Cov}(X, Y) = E(XY) - \mu_X \mu_Y.$$

D. $\mathbf{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)] =$

$$E(XY - X\mu_Y - Y\mu_X + \mu_X\mu_Y) =$$

$$E(XY) - E(X\mu_Y) - E(Y\mu_X) + \mu_X\mu_Y =$$

$$E(XY) - \mu_X\mu_Y$$

Twierdzenie.

Jeśli zmienne losowe X i Y są niezależne, to
$$\text{Cov}(X, Y) = 0$$

D. Dla niezależnych zmiennych losowych

$E(XY) = E(X)E(Y)$. Stąd oraz wzoru na kowariancję mamy:

$$\begin{aligned}\text{Cov}(X, Y) &= E(XY) - \mu_X \mu_Y = \\ &= E(X)E(Y) - \mu_X \mu_Y = 0.\end{aligned}$$

Uwaga. Twierdzenie odwrotne nie jest na ogół prawdziwe.

Przykład

Niech zmienna losowa X ma rozkład jednostajny na zbiorze $\{-1, 0, 1\}$, tzn

$$f_X(-1) = f_X(0) = f_X(1) = \frac{1}{3}$$

Niech $Y = X^2$. Między zmiennymi istnieje deterministyczna zależność, ale $Cov(X, Y) = 0$, ponieważ

$$\begin{aligned} Cov(X, Y) &= E(XY) - E(X)E(Y) = E(X^3) - 0 = E(X) - 0 \\ &= 0 \end{aligned}$$

X, Y – niezależne $\Rightarrow Cov(X, Y) = 0$

$Cov(X, Y) = 0 \not\Rightarrow X, Y$ – niezależne, w przykładzie są zależne mimo że $Cov(X, Y) = 0$

Twierdzenie. Dla dowolnych stałych a, b

$$\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y) + 2ab \text{Cov}(X, Y)$$

D. $E\{ [(aX + bY) - (a\mu_X + b\mu_Y)]^2 \} =$

$$\begin{aligned} E\{ [a(X - \mu_X) + b(Y - \mu_Y)]^2 \} &= E\{ [a(X - \mu_X)]^2 \} \\ &+ E[2ab(X - \mu_X)(Y - \mu_Y)] + E\{ [b(Y - \mu_Y)]^2 \} = \\ &a^2 \text{Var}(X) + 2ab \text{Cov}(X, Y) + b^2 \text{Var}(Y) \end{aligned}$$

Wniosek. Jeśli zmienne losowe X i Y są **niezależne**, to

$$\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y)$$

Definicja. **Współczynnikiem korelacji** między zmiennymi losowymi X i Y nazywamy liczbę:

$$\rho = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)} \sqrt{\text{Var}(Y)}}$$

Przykład. $\rho = ?$

Y	0	1	2
X			
0	0,50	0,05	0,01
1	0,20	0,10	0,06
2	0,02	0,03	0,03

$$\square E(X) = \sum_x \sum_y x f(x, y) = 0 \times (0,5 + 0,05 + 0,01) + 1 \times (0,2 + 0,1 + 0,06) + 2 \times (0,02 + 0,03 + 0,03) = 0,52$$

$$\square E(Y) = \sum_x \sum_y y f(x, y) = 0 \times (0,5 + 0,2 + 0,02) + 1 \times (0,05 + 0,1 + 0,03) + 2 \times (0,01 + 0,06 + 0,03) = 0,38$$

$$\square \quad E(XY) = \sum_x \sum_y xyf(x, y) = 0 + 0 + 0 + 0 + 1 \times 1 \times 0,1 + \\ 1 \times 2 \times 0,06 + 2 \times 1 \times 0,03 + 2 \times 2 \times 0,03 = 0,4$$

$$\square \quad \text{Cov}(X, Y) = 0,4 - 0,52 \times 0,38 = 0,2024$$

$$\square \quad E(X^2) = 0 + 1^2 \times (0,2 + 0,1 + 0,06) + \\ 2^2 \times (0,02 + 0,03 + 0,03) = 0,68$$

$$\square \quad E(Y^2) = 1^2 \times (0,05 + 0,1 + 0,03) + \\ 2^2 \times (0,01 + 0,06 + 0,03) = 0,58$$

$$\square \quad \text{Var}(X) = E(X^2) - [E(X)]^2 = 0,68 - 0,52^2 = 0,4096$$

$$\square \quad \text{Var}(Y) = E(Y^2) - [E(Y)]^2 = 0,58 - 0,38^2 = 0,4356$$

$$\rho = \frac{0,2024}{\sqrt{0,4096} \times \sqrt{0,4356}} = 0,47916$$

Własności współczynnika korelacji

❑ $-1 \leq \rho \leq 1$

❑ Jeśli a i b są stałymi, $Y = a + bX$,

to
$$\rho = \begin{cases} 1 & \text{gdy } b > 0 \\ -1 & \text{gdy } b < 0 \end{cases}$$

❑ Jeśli $|\rho| = 1$, to między zmiennymi losowymi X , Y

istnieje **liniowa zależność funkcyjna**

❑ Jeśli zmienne losowe X i Y są **niezależne**, to

$$\rho = 0$$

Interpretacja.

Współczynnik korelacji jest miarą zależności liniowej między zmiennymi losowymi

Dwuwymiarowy rozkład normalny

Zmienna losowa (X, Y) ma dwuwymiarowy rozkład normalny, jeśli ma gęstość postaci:

$$\frac{1}{2\pi\sigma_X\sigma_Y\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2(1-\rho^2)} \times q(x, y)\right\},$$

gdzie

$$q(x, y) = \frac{(x - \mu_X)^2}{\sigma_X^2} - 2\rho \frac{(x - \mu_X)(y - \mu_Y)}{\sigma_X \sigma_Y} + \frac{(y - \mu_Y)^2}{\sigma_Y^2},$$

$-\infty < x < \infty, -\infty < y < \infty$, stałe σ_X, σ_Y, ρ spełniają warunki

$$\sigma_X > 0, \sigma_Y > 0, -1 < \rho < 1$$

Notacja: $(X, Y) \sim N(\mu_X, \mu_Y, \sigma_X, \sigma_Y, \rho)$

Twierdzenie. Jeśli $(X, Y) \sim N(\mu_X, \mu_Y, \sigma_X, \sigma_Y, \rho)$, to

□ $X \sim N(\mu_X, \sigma_X), \quad Y \sim N(\mu_Y, \sigma_Y)$

□ $\text{Cov}(X, Y) = \rho \times \sigma_X \times \sigma_Y$

□ X, Y są **niezależne** wtedy i tylko wtedy gdy $\text{Cov}(X, Y) = 0$

Twierdzenie. Zmienna losowa (X, Y) ma dwuwymiarowy rozkład normalny wtedy i tylko wtedy gdy zmienna losowa $aX + bY$ ma rozkład normalny, a, b są dowolnymi stałymi