

Statystyczna analiza danych

Wykład 1

STATYSTYCZNA ANALIZA DANYCH

III semestr studiów inżynierskich w PJATK, 2022/23

Prowadzący: dr hab. Elżbieta Ferenstein
dr Andrzej Sierociński

Cel wykładu - poznanie podstaw analizy danych

- statystyka opisowa
- modelowanie probabilistyczne
- wnioskowanie statystyczne



Tematyka wykładu SAD

- Metody graficzne prezentacji danych jakościowych i ilościowych. Statystyki próbkowe. Histogramy a gęstości prawdopodobieństwa, kwantyle, wykresy kwantylowe.
- Prawdopodobieństwo, niezależność zdarzeń, twierdzenie Bayes'a.
- Zmienne losowe, rozkłady prawdopodobieństwa i ich parametry, wybrane rozkłady prawdopodobieństwa.
- Podstawowe statystyki i ich własności, przedziały ufności, testy parametryczne dla średnich i wariancji jednej i dwu populacji, regresja liniowa jednowymiarowa.

Informacje praktyczne

Kontakt:

elaw@pjwstk.edu.pl
asier@pjwstk.edu.pl

Konsultacje: po umówieniu lub po (przed) wykładzie

Wykłady umieszczone są na

ftp/public/elaw/Informatyka dzienne

Ćwiczenia umieszczone są w katalogach Cx na

ftp/public/asier/Informatyka dzienne

Zaliczenie ćwiczeń: skala punktowa: 100 punktów = 90 punktów za 2 kolokwia plus 10 punktów za aktywność (m.in. obecności na ćwiczeniach)

Ocena z ćwiczeń: ≥ 91 pkt: bdb; ≥ 81 pkt: db+; ≥ 71 : db; ≥ 61 : dost +; ≥ 51 : dost.

Ocena dostateczna zalicza ćwiczenia i jest warunkiem dopuszczenia do egzaminu.

Ćwiczenia laboratoryjne - 30% czasu, 70% czasu – ćwiczenia rachunkowe.

Na ćwiczeniach obowiązuje znajomość materiału omawianego na wykładach.

Egzamin: zadania z zakresu wykładu i ćwiczeń.

Wymagania wstępne: Analiza I i II, Matematyka Dyskretna.

Software: Excel.

Literatura

Literatura podstawowa

- Jacek Koronacki, Jan Mielniczuk: *Statystyka dla studentów kierunków technicznych i przyrodniczych*, Wydawnictwa Naukowo-Techniczne 2001.
- David S. Moore, George P. McCabe: *Introduction to the Practice of Statistics*, W.H. Freeman&Co., 2000.
- Jay L. Devore: *Probability and Statistics for Engineers and the Sciences*, 1987.

Literatura uzupełniająca

- Janina Jóźwiak, Jarosław Podgórski: *Statystyka od podstaw*, PWE, Warszawa 2001(3), wyd. V (VI).
- Przemysław Grzegorzewski i inn.: *Rachunek prawdopodobieństwa i statystyka*, WSISiZ, Warszawa 2001.
- Amir D. Aczel: *Statystyka w zarządzaniu*, PWN, Warszawa 2000.
- K. Bobeck, P. Grzegorzewski, J. Pusz: *Zadania z rachunku prawdopodobieństwa i statystyki*, WSISiZ, Warszawa 2003.
- Mieczysław Sobczyk: *Statystyka*, PWN 2005.

Podręczniki w wersji elektronicznej (e-booki)

- <http://www.stat.rice.edu/~dobelman/textfiles/DistributionsHandbook.pdf>
- <http://davidmlane.com/hyperstat/index.html>

STATYSTYKA OPISOWA

Techniki wstępnej analizy danych i ich prezentacji:

- **gromadzenie**, przechowywanie danych, analiza danych surowych
- **prezentacja** danych: tabele, wykresy, parametry liczbowe obliczane dla danych.

Cel:

- **charakteryzacja** danych - w **zwięzłej formie** odzwierciedlająca pewne ich **cechy**, np. średni dochód, średnie zużycie paliwa, ..
- **odnalezienie** różnego rodzaju **regularności** (nieregularności) ukrytych w danych, **zależności** między podzbiorami danych.

- ❑ Obejrzenie danych surowych – nieprzetworzonych, niepogrupowanych, niezorganizowanych.
- ❑ Poznanie sposobu i celu zebrania danych:
 - ◆ jaką cechą mierzono (obserwowano) ?,
 - ◆ w jakich jednostkach ?,
 - ◆ ile wykonano obserwacji (liczebność zbioru danych), w jakich warunkach – czy nie zgubiono części danych, dane brakujące, czy jest możliwość przekłamań ?
 - ◆ czy celem zebrania danych ma być odpowiedź na konkretne pytania ?

- ❑ Cel badania statystycznego: poznanie charakterystyk dużej zbiorowości obiektów (osoby, przedmioty, zjawiska, możliwe wyniki eksperymentów ...) na podstawie obserwacji cech (danych) jedynie niektórych wylosowanych obiektów
- ❑ **Populacja:** zbiór obiektów badanych ze względu na określoną cechę nazywaną **zmienną**
- ❑ **Próbka:** zbiór cech zbadanych obiektów populacji

Rodzaje i przykłady cech statystycznych

- Ilościowe
 - Ciągłe : wzrost, waga itp.
 - Dyskretne : liczba dzieci, liczba reklamacji itp.
- Jakościowe
 - O kategoriach uporządkowanych: miasta (małe, średnie, duże), rodziny (bezdzietne, wielodzietne) itp.
 - Nominalne : grupa krwi, płeć, kolor oczu itp.

- **Badanie statystyczne pełne** (kompletne, całkowite, wyczerpujące) to badanie oparte o dane obejmujące wszystkie jednostki populacji.
- **Badanie statystyczne częściowe** (niekompletne, niepełne) to badanie oparte o dane obejmujące wybrane jednostki populacji.
- **Próba** to podzbiór populacji generalnej wykorzystywany w badaniu częściowym.
- **Próba reprezentatywna** to próba wybrana w sposób losowy i mająca dostateczną liczebność.
Aby wyniki badania próby można było odnieść do zbiorowości generalnej (uogólnić) próba musi być reprezentatywna.

Populacja

badana cecha (zmienna)

zebrane dane (próbka)

♦ zbiór detali	jakość detalu	zbiór jakości zbadanych detali
♦ zbiór komputerów w sieci	liczba awarii komputera w danym okresie	zbiór liczb awarii wybranych komputerów w danym czasie
♦ zbiór projektów przysyłanych na konkurs	ocena projektu	zbiór ocen wybranych projektów
♦ zbiór osób w zespole pracowników	staż pracy	zbiór staży pracy (lat pracy) wylosowanych osób

Opracowanie materiału statystycznego

- **Szereg szczegółowy (wyliczający)** – uporządkowany ciąg obserwowanych wartości badanej cechy statystycznej.
- **Szereg rozdzielczy (strukturalny)** – materiał statystyczny podzielony na grupy (klasy) według wybranego kryterium, zapisany w postaci tabelarycznej, z podaniem liczebności (lub częstości) każdej z wyodrębnionych grup,.
- Szeregi rozdzielcze są wynikiem operacji grupowania danych.
- W przypadku cechy mierzalnej z małą liczbą wariantów cechy tworzy się szeregi rozdzielcze **punktowe**.
- Gdy wariantów jest dużo buduje się szeregi rozdzielcze **przedziałowe**.
- Szereg rozdzielczy cechy mierzalnej opisuje **rozkład empiryczny** badanej cechy.

Przykład (szereg rozdzielczy punktowy)

Liczba pracowników w poszczególnych przedsiębiorstwach pewnego koncernu wynosi:

100; 125; 170; 144; 144; 235; 301; 100; 100; 170; 144; 235; 100; 301; 170; 301; 125; 125; 235, 125:125; 100; 144; 301; 144; 144; 170; 144; 144; 144.

Są to tzw. *dane surowe*. Opisują cechę mierzalną skokową.

Po uporządkowaniu danych (np. rosnąco) dostajemy szereg wyliczający (zapisany 2 wierszach tabeli).

Ponieważ w zbiorze danych mamy tylko 5 wariantów cechy tworzymy szereg rozdzielczy punktowy postaci

Grupa	Liczebność
100	5
125	5
144	9
170	4
235	3
301	4
SUMA	30

Przykład (szereg rozdzielczy przedziałowy)

Powierzchnie użytkowe (w m²) badanych sklepów przedstawia uporządkowany szereg wartości cechy:

76; 81; 83; 85; 87; 91; 93; 94; 95; 97; 99; 104;
111; 112; 113; 114; 116; 118; 119; 120; 121; 122; 123; 125;
126; 127; 128; 128; 129; 130; 131; 132; 133; 133; 135; 135;
136; 137; 138; 138; 141; 141; 141; 141; 143; 144; 146; 146;
148; 148; 152; 155; 158; 159; 161; 162; 163; 165; 166; 167;
178; 179; 179; 182; 184; 184; 193, 198; 200.

Powierzchnia jest cechą mierzalną ciągłą, dlatego przeprowadzimy grupowanie statystyczne danych tworząc szereg rozdzielczy, z przedziałami klasowymi o rozpiętości 20 m² i początkiem pierwszego przedziału klasowego równym 70 m².

Otrzymany szereg rozdzielczy (liczebności) ma postać:

przedział	70-90	90-110	110-130	130-150	150-170	170-190	190-210
liczebność	5	7	17	21	10	6	3

(przyjęto przedziały lewostronnie domknięte, prawostronnie otwarte)

Szereg rozdzielczy częstości uzyskujemy zastępując liczebności przez odpowiadające im częstości (częstości względne)

$$\text{częstość} = (\text{liczebność grupy}) / (\text{liczebność łączna}) \quad \left(w_i = \frac{n_i}{N} \right)$$

Szereg rozdzielczy częstości dla prezentowanych danych ma postać

przedział	70-90	90-110	110-130	130-150	150-170	170-190	190-210
częstość	0,07	0,10	0,25	0,30	0,14	0,09	0,04

w ujęciu procentowym

przedział	70-90	90-110	110-130	130-150	150-170	170-190	190-210
częstość	7%	10%	25%	30%	14%	9%	4%

Szeregi rozdzielcze skumulowane

przedział	70-90	90-110	110-130	130-150	150-170	170-190	190-210
liczebność skumulowana	5	12	29	50	60	66	69

przedział	70-90	90-110	110-130	130-150	150-170	170-190	190-210
częstość skumulowana	0,07	0,17	0,42	0,72	0,87	0,96	1,00

przedział	70-90	90-110	110-130	130-150	150-170	170-190	190-210
częstość skumulowana (%)	7%	17%	42%	72%	87%	96%	100%

Przykład. W 30 rzutach kostką sześcienną otrzymano liczby oczek:

3 5 6 1 4 6 2 3 5 6 2 6 5 3 5 4
6 6 5 1 5 2 4 3 6 1 1 2 1 3 3 6

wartość (liczba oczek)

1 2 3 4 5 6

liczność (liczba wystąpień)


5 4 6 3 5 7

częstość

$\frac{5}{30}$ $\frac{4}{30}$ $\frac{6}{30}$ $\frac{3}{30}$ $\frac{5}{30}$ $\frac{7}{30}$


Diagram liczebności

Wykres słupkowy



Liczba oczek

Wykres kołowy



Metody opisu danych jakościowych

wykres słupkowy, wykres kołowy

Przykład. Liczby studentów w kraju na różnych kierunkach studiów w roku ak. 1990/91 oraz 1997/98

podane są w tabeli. Wykonamy:

- wstępną analizę danych
- wykresy słupkowe (procentowe, ilościowe)
- wykresy kołowe

Prezentacja materiału statystycznego

Tablica danych

Grupa kierunków	rok 1990/91		rok 1997/98	
	liczba	%	liczba	%
pedagogiczne	99552	18,3	91100	7,2
humanistyczne	69088	12,7	110565	8,7
prawne i nauki społeczne	133824	24,6	566475	44,8
nauki ścisłe i przyrodnicze	144704	26,6	292110	23,1
medyczne	81600	15,0	95550	7,6
pozostałe	15232	2,8	109200	8,6
ogółem	544000	100,0	1265000	100,0

Prezentacja materiału statystycznego

Opis danych surowych:

- 2 próbki o licznosciach $n_1 = 544000$ oraz $n_2 = 1265000$
- cecha jakościowa: grupa kierunków studiów
- 6 kategorii (atrybutów) cechy
- atrybuty: grupa kierunków pedagogicznych, humanistycznych, medycznych,

Najliczniejsze grupy kierunków:

- nauki ścisłe i przyrodnicze w 1990/91 roku
- prawo i nauki społeczne w 1997/98 roku


Procentowy udział klasy

$$(\text{liczność klasy} / \text{liczność próbki}) * 100\% = \text{częstość} * 100\%$$

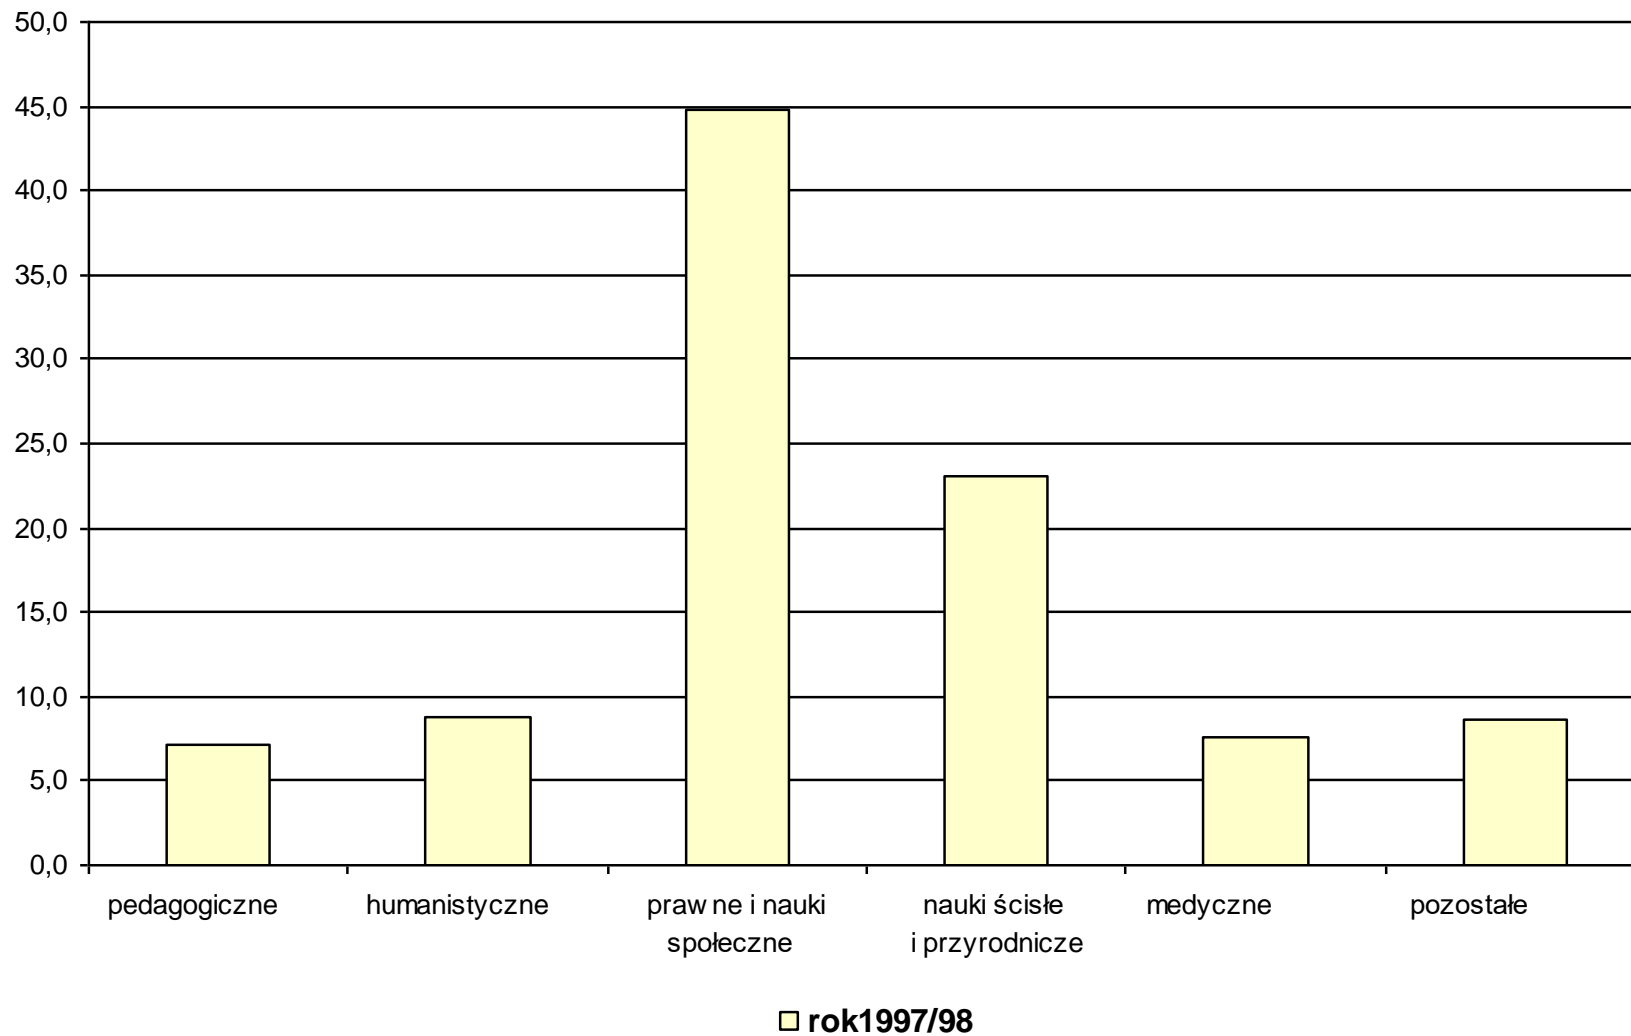
Prezentacja materiału statystycznego

Wykres słupkowy

Wykres słupkowy procentowego udziału grup kierunków studiów
w roku akad. 1990/91




Wykres słupkowy procentowego udziału grup kierunków studiów
w roku akad. oraz 1997/98



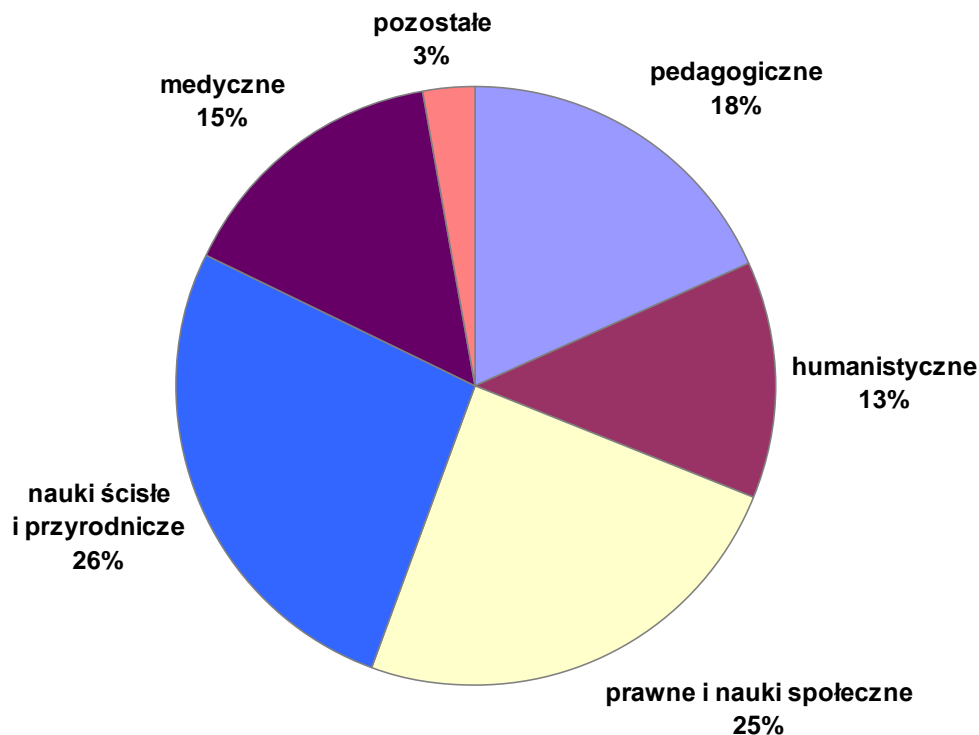
Prezentacja materiału statystycznego

Połączony wykres słupkowy



Wykres kołowy

**Wykres kołowy procentowego udziału grup kierunków studiów
w roku akad. 1990/91**



Kąt wycinka koła dla grupy humanistycznej =

$$0,127 \times 360^{\circ} = 45,72^{\circ}$$

Kąt wycinka koła odpowiadającego określonej kategorii =

Liczebność kategorii / liczebność próbki) $\times 360^{\circ}$.


$$\text{częstość kategorii} \times 100\% =$$

$$= (\text{pole wycinka} / \text{pole koła}) \times 100\%$$

Prezentacja materiału statystycznego

Wykres kołowy


**Wykres kołowy procentowego udziału grup kierunków studiów
w roku akad. 1997/98**




Prezentacja materiału statystycznego

Wykresy kołowe

Wykres kołowy procentowego udziału grup kierunków studiów w roku akad. 1990/91




Wykres kołowy procentowego udziału grup kierunków studiów w roku akad. 1997/98



Wykres słupkowy

Przykład

Tablica xx. Wartość eksportu krajów członkowskich UE w okresie 2006 I-X (ceny bieżące w mld EUR)




Źródło: http://www.stat.gov.pl/cps/rde/xbcr/gus/PUBL_unia_europejska_wskazniki_krotkookresowe_01_2007.xls

Wykres kołowy

Przykład

Tablica xx. Wartość eksportu krajów członkowskich UE w okresie 2006 I-X (ceny bieżące w mld EUR)



Źródło:

http://www.stat.gov.pl/cps/rde/xbcr/gus/PUBL_unia_europejska_wskazniki_krotkookresowe_01_2007.xls

Ograniczenia wykresów kołowych:

- ❑ można przedstawić jedynie dane procentowe
- ❑ w próbkce musi być co najmniej 1 obserwacja każdej kategorii (bo łączna suma pól wycinków musi stanowić 100 % pola koła)
- ❑ mało czytelne przy dużej liczbie kategorii
- ❑ analiza dwóch wykresów kołowych bardziej kłopotliwa niż połączonego wykresu słupkowego.

METODY OPISU DANYCH IŁOŚCIOWYCH SKALARNYCH

Wykresy: diagramy, histogramy, łamane częstości,
wykresy przebiegu.

Przykład. W stu kolejnych rzutach kostką sześcienną
otrzymano wyniki (próbkę cechy dyskretnej o liczności
100):

5 2 2 6 3 2 5 3 1 2 5 3 6 2 5 4 4 6 1 6 4 5 5 2 4 6 1 4 4 3 4 2 4 2 4 4
1 1 4 5 3 1 5 6 5 6 1 5 6 2 4 5 5 2 5 4 5 5 1 1 2 2 5 5 2 6 3 5 5 4 1 4
5 5 1 4 3 2 1 2 6 1 2 1 6 5 1 3 6 1 5 6 6 2 2 3 5 5 2 4

Rozkład liczby oczek w próbce

<u>Wartość</u> (l. oczek)	1	2	3	4	5	6
<u>Liczność</u> (l. wystąpień)	16	19	9	17	25	14

Rozkład częstości liczby oczek w próbce

<u>Wartość</u> (l. oczek)	1	2	3	4	5	6
<u>Częstość</u>	0,16	0,19	0,09	0,17	0,25	0,14

Zwięzły opis próbki: **rozkład cechy w próbce**, tzn. zapisanie jakie wartości wystąpiły w próbce i ile razy, lub z jaką częstością.

Diagram liczebności

Diagram częstości


Przykład. Wiek **25** osób, które ubezpieczyły się w III filarze emerytalnym w pewnym zakładzie pracy: 30, **49**, 33, 35, 37, **20**, 31, 30, 36, 46, 39, 40, 38, 41, 35, 37, 24, 27, 36, 43, 45, 25, 32, 29, 28.

- ❑ **21 różnych wartości:** diagram rozkładu lat nieczytelny.
- ❑ **Agregacja danych:** przedziały wiekowe zawierające wszystkie obserwacje, liczba obserwacji w tych przedziałach.

Tabela liczności i częstości

Przedział	Obserwacje	Liczność	Częstość
(19;25]	20,24,25	3	12%
(25;31]	27,28,29,30,30,31	6	24%
(31;37]	32,33,35,35,36,36,37,37	8	32%
(37;43]	38,39,40,41,43	5	20%
(43;49]	45,46,49	3	12%

Histogram częstości wieku



Na osiach poziomych: granice klas wiekowych (przedziałów)
wysokości słupków = procentowy udział każdej klasy w próbkce

Wysokość słupka = częstość klasy x 100%.

Pole słupka =

stała długość przedziału x częstość x 100

Histogram **liczebności**: wysokość słupka = **liczność klasy**

Histogram **częstości**: wysokość słupka = **częstość klasy**

Niech x_1, x_2, \dots, x_n będzie n – elementową próbką.

Rozstępem z próbki nazywamy liczbę

$$R = x_{max} - x_{min} := x_{(n)} - x_{(1)}.$$

Przy większej liczności próbki ($n > 30$), w celu ułatwienia analizy danych, wartości liczbowe próbki grupuje się w **klasach** (przedziałach najczęściej o jednakowej długości), przyjmując uproszczone założenie, że wszystkie wartości znajdujące się w danej klasie są identyczne ze środkiem przedziału. W wyniku grupowania otrzymujemy szereg rozdzielczy i histogram.

SZEREK ROZDZIELCZY i HISTOGRAM

Szeregiem rozdzielczym nazywamy ciąg par

$$(\bar{x}_i, n_i), i = 1, \dots, k,$$

gdzie \bar{x}_i jest środkiem i – tej klasy.

Ciąg $\{n_i\}$ nazywamy rozkładem licznosci przy danej liczbie klas.

Początkowy wybór długości przedziałów:

$$h = 2,64 \cdot IQR \cdot n^{-1/3}$$

n = liczność próbki

IQR = rozstęp międzykwartylowy = zakres 50% środkowych wartości w próbce (po uporządkowaniu rosnąco)

Długość klasy - h

$$h \cong \frac{R}{k}, \quad \text{bo musi zachodzić } h \cdot k \geq R.$$

Punkty stanowiące granice poszczególnych klas ustala się z dokładnością do $\frac{d}{2}$, gdzie d jest dokładnością pomiaru (lub przyjmuje się przedziały jednostronnie otwarte, aby każdy element próbki należał tylko do jednej klasy).

Oznaczmy przez n_i licznosc i – tej klasy. Stąd

$$\sum_{i=1}^k n_i = n.$$

Liczba klas - k .

Liczność próbki n	Liczba klas k
30 - 60	6 – 8
60 – 100	7 – 10
100 - 200	9 – 12
200 – 500	11 – 17
500 – 1500	16 – 25

Na ogół nie stosuje się liczby klas k większej od 30.

Praktyczna metoda ustalania
liczby klas **k** i szerokości **h**
w próbie o liczności **n** i rozstępie **R**

- $k = \lfloor \sqrt{n} \rfloor \text{ lub } \lceil \sqrt{n} \rceil$
- $h = \left\lceil \frac{R}{k} \right\rceil$
- Zalecane jest stosowanie przedziałów grupowania postaci (;] (otwarto - domkniętych)
- Pierwszy przedział może, w razie potrzeby, być domknięty – [;].

Mała długość przedziału to : **nieregularność** histogramu

Duża długość przedziału to: za duże **wygładzenie** histogramu

Przy ustaleniu kompromisu pomiędzy zbyt dużym wygładzeniem histogramu (redukcją informacji) a dużą nieregularnością histogramu pomocne są dodatkowe informacje o naturze obserwowanego zjawiska, np. obserwacje z kilku różnych populacji mogą dawać histogramy wielomodalne.

❑ **Początek histogramu:** najmniejsza obserwacja stanowi środek pierwszego przedziału. Uśredniając kilka histogramów o nieznacznie przesuniętych początkach można uniezależnić się od wpływu początku histogramu na jego kształt.

Przykład. Wkładka topikowa bezpiecznika o natężeniu znamionowym 20A winna, zgodnie z normą, wytrzymać bez przepalenia się natężenie 28A w ciągu 1 godziny. W celu sprawdzenia zgodności z normą, z partii wkładek topikowych tego typu pobrano losowo 40 sztuk i zanotowano czasy przepalenia się wkładki przy natężeniu prądu 28A. Otrzymano następujące wyniki w minutach:

51	58	64	69	61	56	41	48	56	61
75	55	46	57	70	55	47	62	55	60
54	57	65	60	53	54	49	58	62	59
53	50	58	63	64	59	52	51	65	60

Dla przedstawionej próbki zbudować szereg rozdzielczy oraz narysować histogram i łamaną częstości.

Rozwiązanie.

Zauważmy, że $x_{min} = 41$ oraz $x_{max} = 75$.


Stąd rozstęp z próbki: $R = 75 - 41 = 34$.

Ponieważ liczność próbki $n = 40$, to wygodnie jest przyjąć liczbę klas $k = 7$ oraz szerokość klasy $h = 5$.

Tym samym otrzymujemy szereg rozdzielczy:

Nr klasy i	Klasa		\bar{x}_i	n_i	w_i	N_i	W_i
1	40,5	45,5	43	1	0,025	1	0,025
2	45,5	50,5	48	5	0,125	6	0,150
3	50,5	55,5	53	10	0,250	16	0,400
4	55,5	60,5	58	12	0,300	28	0,700
5	60,5	65,5	63	9	0,225	37	0,925
6	65,5	70,5	68	2	0,050	39	0,975
7	70,5	75,5	73	1	0,025	40	1,000

Histogram oraz łamana licznosci



WSKAŹNIKI SUMARYCZNE

WSKAŹNIKI POŁOŻENIA (miary położenia, parametry położenia) charakteryzują najbardziej reprezentatywne dane, centralną „tendencję” danych, określają „środek” próbki:

Niech : x_1, x_2, \dots, x_n - próbka o liczności n .

Wartość średnia w próbce (średnia próbkowa, średnia próbki)

$$\bar{x} = \frac{1}{n} (x_1 + x_2 + \dots + x_n) = \frac{1}{n} \sum_{i=1}^n x_i$$

Przykład. Miesięczny dochód 10-ciu osób (w tys. PLN):

Dochód (PLN)	[1, 1,5]	(1,5, 2]	(2, 2,5]	(2,5, 3]
Liczba osób	2	2	4	2

Średnia na podstawie danych zgrupowanych:

$$\bar{x} = \sum_{i=1}^k \frac{n_i \tilde{x}_i}{n} = \frac{2 \times 1,25 + 2 \times 1,75 + 4 \times 2,25 + 2 \times 2,75}{10} = 2,05$$

Mediana w próbce (mediana próbki, mediana próbkowa)

Niech $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n-1)} \leq x_{(n)}$

uporządkowane w sposób rosnący wartości próbki:

$$x_{(1)} = \min\{x_1, x_2, \dots, x_n\}, \dots, x_{(n)} = \max\{x_1, x_2, \dots, x_n\}$$

$$x_{med} = x_{((n+1)/2)}, \quad \text{gdy } n \text{ jest nieparzyste}$$

$$x_{med} = \frac{1}{2}(x_{(n/2)} + x_{(n/2+1)}), \quad \text{gdy } n \text{ jest parzyste.}$$

Przykład. Miesięczny dochód 11-tu osób:

Dochód (PLN)	2000	2500	3500	19000
Liczba osób	4	4	2	1

Średnie wynagrodzenie tej grupy osób to:

$$\bar{x} = \frac{1}{11} (4 \times 2000 + 4 \times 2500 + 2 \times 3500 + 19000) = \mathbf{4000}$$

2000, 2000, 2000, 2000, 2500, 2500, 2500, 2500, 3500, 3500, 19000

Mediana = 2500

Średnia wrażliwa na obserwacje odstające:

$\bar{x} = 4000 > 3500 = x_{(10)}, x_{(11)} = 19000$ - **średnia nie odzwierciedla „typowego” dochodu.**

Mediana odporna (mało wrażliwa) na obserwacje odstające:

$x_{med} = x_{(6)} = 2500$ - **mediana jest lepszą miarą przeciętnego wynagrodzenia niż średnia**

Średnia ucinana (**ucięta**) (z parametrem k)

$$\bar{x}_{tk} = \frac{1}{n - 2k} \sum_{i=k+1}^{n-k} x_{(i)},$$

stosowana gdy wartości odstające są wynikiem błędu (błędne przetworzenie danych lub błędy przyrządów pomiarowych).

Ostrzeżenie: obserwacje odstające mogą być bardzo istotne, np. są wynikiem rozregulowania procesu produkcji

Średnia winsorowska (z parametrem k)

$$\bar{x}_{wk} = \frac{1}{n} \left[(k+1)x_{(k+1)} + \sum_{i=k+2}^{n-k-1} x_{(i)} + (k+1)x_{(n-k)} \right]$$

Stosowana w sytuacjach gdy wartości skrajne (k najmniejszych lub k największych) niepewne co do ich prawdziwych wartości (np. zostały utracone z bazy danych; nie mogły być zaobserwowane w przypadku badania czasu życia lub czasu bezawaryjnej pracy urządzenia gdy eksperymentator ma ograniczony czas obserwowania zjawiska.

Moda – najczęściej występująca wartość (lub wartości) w próbce.

WSKAŹNIKI ROZPROSZENIA (**miary rozproszenia**, **parametry rozproszenia**) charakteryzują rozrzut danych, rozproszenie wartości próbki wokół parametru położenia.

Rozstęp próbki

$$R = x_{(n)} - x_{(1)},$$

Wariancja próbki (**w próbce**)

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2,$$

Przykład. Miesięczny dochód 10-ciu osób (w tys. PLN):

Dochód (PLN)	[1, 1,5]	(1,5, 2]	(2, 2,5]	(2,5, 3]
Liczba osób	2	2	4	2

Wariancja na podstawie danych zgrupowanych:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^k n_i (\tilde{x}_i - \bar{x})^2 = 0,2889.$$

Odchylenie standardowe w próbce (próbki)

$$s = \sqrt{s^2}$$

Odchylenie przeciętne od wartości średniej

$$d_1 = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$$

Dolny (pierwszy) kwartyl

Q_1 = mediana podpróbki składającej się z elementów próbki „mniejszych” od mediany x_{med} .

Górny (trzeci) kwartyl

Q_3 = mediana podpróbki składającej się z elementów próbki „większych” od mediany (w próbce uporządkowanej rosnąco są to elementy występujące na pozycjach po pozycji mediany).


Rozstęp międzykwartylowy

$$IQR = Q_3 - Q_1.$$

WYKRES RAMKOWY (pudełkowy)

ilustruje wzajemne położenie pięciu wskaźników sumarycznych:

$$x_{(1)} = x_{min}, \quad Q_1, \quad x_{med}, \quad Q_3, \quad x_{(n)} = x_{max}.$$



Obserwacja
potencjalnie
odstająca

Z wykresu odczytujemy następujące wskaźniki:

- $Q_1 = 0,1$ = rzut na oś poziomą lewego boku prostokąta
- $Q_3 = 0,7$ = rzut na oś poziomą prawego boku prostokąta
- $Q_2 = 0,3$ = rzut na oś poziomą pionowego odcinka wewnątrz prostokąta
- IQR = długość podstawy prostokąta

Wąsy wykresu ramkowego = linie po obu stronach prostokąta.

Rzut lewego wąsa na oś poziomą = przedział $[x^*, Q_1]$, gdzie


$$x^* = \min\{ x_k: Q_1 - 3/2 \cdot IQR \leq x_k \leq Q_1 \},$$

podobnie określamy rzut prawego wąsa = przedział $[Q_3, x^*]$, gdzie


$$x^* = \max\{ x_k: Q_3 \leq x_k \leq Q_3 + 3/2 \cdot IQR \}$$

Count = 100
Average = 2,02544
Median = 1,46467
Variance = 3,16395
Standard deviation = 1,77875
Minimum = 0,0150559
Maximum = 8,05684
Range = 8,04179
Lower quartile = 0,638618
Upper quartile = 3,23695
Interquartile range = 2,59833
Coeff. of variation = 87,8206%


Box-and-Whisker Plot



Histogram



Box-and-Whisker Plot



Summary Statistics for RAND1

Count = 100

Average = -0,110696

Median = -0,0516888

Variance = 1,07775

Standard deviation = 1,03815

Minimum = -3,36516

Maximum = 2,26235

Range = 5,62751

Lower quartile = -0,726224


Upper quartile = 0,680553

Interquartile range = 1,40678

Std. skewness = -1,86072


Coeff. of variation = -937,836%

Box-and-Whisker Plot



RAND1

Histo gram



Box- and -W hisker Plot

